

빅데이터 프로그래밍

오남 팀 프로젝트
중간발표

목차

01

프로젝트 개요

02

관련 연구 및 기술 배경

03

실험 데이터

04

모델 설계

05

실험 및 평가 방법

06

실험 결과 및 해석

07

프로젝트 일정 및 역할 분배

08

중간 결론 및 향후 계획

01. 프로젝트 개요

프로젝트 수행 배경

- 리뷰 이벤트의 객관적이지 못한 별점으로 배달 플랫폼에서 리뷰를 믿기 어려워짐
→ 이를 완화하여 리뷰의 신뢰성 회복
- 선행 연구 결과 소비자 대부분이 리뷰 이벤트가 과장된 것을 인식하면서도 주문 시 리뷰와 별점에 의존하는 경향을 보임
→ 별점 정제 기능을 구현하여 소비자의 의사 결정을 도움

프로젝트 목표


- 텍스트의 문맥적 특징과 메타데이터를 결합한 **리뷰 이벤트 판별 시스템**
- 리뷰 이벤트 여부를 자동으로 판별하고 **정제된 별점 산출**

01. 프로젝트 개요

연구 질문 및 가설

- **연구 질문:** 이벤트성 리뷰는 일반 리뷰와 어떤 구체적인 차이를 드러내는가?
- **가설:** 이벤트 참여 유저는 리뷰 이벤트 직접 언급을 하거나 혹은, 반복적이고 무조건적인 칭찬 등 텍스트 문맥상 부자연스러운 패턴과 비정상적인 리뷰 길이, 과도한 이모지 사용 등 특이한 행동 특성을 보일 것이다

프로젝트 구조



02. 관련 연구 및 기술 배경

기존 가짜 리뷰 탐지 연구 동향

기존 리뷰 탐지 연구

- 리뷰 텍스트 길이, 중복·유사 리뷰 등 단순 통계 및 키워드에 의존함

최신 동향

- TF-IDF, Word2Vec을 넘어 BERT 계열의 사전학습 언어모델을 활용하여 리뷰 문장의 문맥적 의미를 반영하는 방식이 활발히 연구되고 있음
- 특히 WF-CFRB(2025) 연구 등에서 텍스트 문맥과 리뷰어의 행동 특징을 융합하여 가짜 리뷰 탐지 성능을 향상시키는 방식을 제안

02. 관련 연구 및 기술 배경

기존 접근 방식의 한계점

- 기존 통계기반 모델/키워드 필터링 모델은 이벤트 관련 키워드가 없으면 이를 감지하지 못함
- 기존 관련 연구들은 대부분 영어 데이터 기반이라서 한국어 리뷰의 특징을 반영하기 어려움
- 일부 한국어 데이터 기반 연구도 특정 지역에 국한된 데이터를 사용하여 일반화가 어려움

본 프로젝트의 차별성 및 보완점

- 단어 빈도수, 특정 키워드 검출이 아닌 문맥 정보를 반영할 수 있는 KcBERT를 특징 추출기로 사용
- 추출된 특징과 리뷰 데이터의 메타데이터를 활용하여 특징 벡터를 구성
- 이후 MLP 이진 분류 모델을 학습하여 리뷰 이벤트 여부를 판별
- 모델이 산출한 이벤트 리뷰 확률을 활용하여 별점 정제 기능 구성

03. 실험 데이터

데이터 수집

해시스크래퍼의 배달의 민족 리뷰 수집 크롤링 봇 사용

- 기존 프로젝트의 한계점 극복을 위해 **다양한 지역의 한국어 데이터** 수집
- 단순 리뷰 원문만이 아닌, 사진, 메뉴, 별점 등 추가 활용 가능한 데이터를 포함
- 직접 이벤트성/일반 리뷰의 비율을 확인하면서 정렬을 추천순/별점 높은 순 번갈아가며 수집
- 컬럼명 서로 다를 수 있는 공개 데이터에 비해서 전처리 시간 감소
- **비교적 최신의 리뷰 데이터**
- 모델 학습을 위한 기반으로 사용 가능

Kaggle, Mendeley Data 등 공개 데이터 활용

- 컬럼명이 서로 다름
- **특정 지역 국한**되어 있거나 **최신의 데이터가 아닐 수 있음**
- 모델 테스트 시 사용 가능

03. 실험 데이터

데이터의 형태

- (URL, NAME, RATING, CONTENT, MENU, DATE, IMAGE_URLS, OWNER_REPLY, created_at)

데이터 라벨링

- 판별하는 기준은 **주문 메뉴(MENU)**에 리뷰 이벤트 전용 메뉴 포함 여부
- MENU 에서 '**리뷰**', '**event**', '**review**', '**이벤트**'와 같은 단어가 포함된 경우 리뷰 이벤트성 참여 데이터로 라벨링 수행
→ 이벤트성 리뷰(1)/일반 리뷰(0)

데이터 병합

- 서울 남부/북부, 인천, 부산 지역으로 나누어 수집한 데이터 엑셀 파일을 하나로 통합

03. 실험 데이터

데이터 전처리 기준

- 중복 크롤링된 리뷰는 삭제
- 한글 컬럼은 영어 컬럼으로 변환하고, 분석 필요성 낮은 컬럼은 삭제
- 다른 컬럼은 메타데이터로 활용하고, 결측 데이터는 제외

KcBERT에 맞게 데이터 전처리

- KcBERT에서 권장하는 clean 함수 적용
→ clean 함수 적용 시, 불필요한 토큰 발생 감소 및 임베딩 품질 증가
- 모델에 적용할 수 있도록 원문 리뷰와 모델 학습용 정제 리뷰를 생성

메타데이터 생성

- 리뷰 텍스트 데이터와 메뉴 컬럼을 제외한 컬럼으로 메타데이터 사용
- 리뷰 텍스트 길이, 이모지 개수, 사진 유무 및 개수를 메타데이터로 사용
- 데이터 분할 후 **학습 데이터에 정규화 수행**

03. 실험 데이터

최종 데이터 형태

- (store_url, store_name, rating, review_text, menu_name, image_urls, source_file, review_text_raw, menu_name_raw, **label**, **cleaned_review_text**, has_photo, photo_count, text_length, emoji_count)
- label: 리뷰 이벤트 여부
- cleaned_review_text: KcBERT 입력용 정제된 텍스트 데이터

store_url	store_name	rating	review_text	menu_name	image_urls	source_file	review_text_raw	menu_name_raw	label	cleaned_review_text	has_photo	photo_count	text_length	emoji_count
0qf6FaBDp	타타스베이글 천호점	5.0	타타스베이글 천호점 후기 🍪💙\n맨날 지나가면서 포장만 하다가 이번엔 배민 픽업으로 ...	리뷰이벤트) 랜덤 크림치즈 1개,과일의 여왕 무화과 베이글,캔 카페라떼 (500ml)	["https://bmreview.cdn.baemin.com/bmreview-qh2...	서울남부_배달의민족_리뷰_통합.xlsx	타타스베이글 천호점 후기 🍪💙\n맨날 지나가면서 포장만 하다가 이번엔 배민 픽업으로 ...	리뷰이벤트) 랜덤 크림치즈 1개,과일의 여왕 무화과베이글,캔 카페라떼 (500ml)	1	타타스베이글 천호점 후기 맨날 지나가면서 포장만 하다가 이번엔 배민 픽업으로 주문해...	1	1	182	12

03. 실험 데이터

탐색적 데이터 분석 결과

- 일반 리뷰 대비 이벤트 리뷰 수가 현저히 떨어지는 **클래스 불균형 문제**를 확인함
- 이벤트성 리뷰에서 리뷰 텍스트 길이와 이모지 사용 빈도의 평균값이 일반 리뷰 보다 높은 경향이 확인되지 않음
- 평균 사진 수는 이벤트 리뷰가 일반 리뷰 보다 높지만, 이벤트 유무를 구분하는 특성으로 보기에는 어려움

항목	일반 리뷰	이벤트 리뷰
데이터 수	5,690	3,150
비율	64.4%	35.6%
평균 리뷰 길이	57.7	54.7
평균 이모지 수	0.7	0.6
평균 사진 수	0.9	1.0

04. 모델 설계

특징 추출용 모델: KcBERT

모델 선정 이유

- BERT 모델은 TF-IDF나 Word2Vec과 같은 단순 빈도수 계산 기반이 아닌 해당 단어가 문장에서 **어떻게 사용되는지 문맥을 고려**
 - 탐색적 데이터 분석 결과, 단순 통계적 특성으로는 리뷰 이벤트 여부를 판단하기 어려움
 - 문장을 다른 모델의 입력으로 사용할 수 있도록 **벡터화 가능**
 - 다만, 일반적인 BERT 모델은 영어 텍스트 기반으로 학습된 모델이기 때문에 한국어 리뷰가 주된 데이터이기에 이를 위한 **한국어 맞춤 모델**이 필요
 - 또한 위키백과 기반의 일반 KoBERT와 달리, 리뷰는 정제되지 않은 구어체 데이터 특성이 강하기 때문에 사전 학습된 KcBERT가 배달 리뷰 도메인에 가장 적합하다고 판단
- 따라서 **신조어, 오타자, 초성 표현**이 많고 **구어체** 특성이 강한 KcBERT를 프로젝트에서 사용

04. 모델 설계

KcBERT 모델 활용 방안

임베딩 벡터 추출

임베딩 추출 전 데이터 형태: (8840, 15)

임베딩 추출 후 데이터 형태: (8840, 768)

- 프로젝트의 목표를 리뷰 이벤트성 리뷰인지 아닌지 **분류 문제**로 해석
 - 이진 분류 모델에 적용할 수 있도록 벡터 형태의 특징이 필요
 - KcBERT에 분류층을 추가하는 형식으로도 가능, 하지만 비용 증가
 - KcBERT를 fine-tuning 하지 않고 **사전 학습 가중치를 고정한 특징 추출기로 사용**
- 사전 학습된 KcBERT에 추가 학습 없이, 리뷰 원문에서 **768차원의 임베딩 벡터를 추출**
- 텍스트 외의 메타데이터를 활용하는 방식으로 접근
 - 텍스트 정보만 학습시키는 방식은 메타데이터 반영 어려움 존재
 - **따라서 이진 분류 모델에 메타데이터와 벡터를 조합하는 방법 채택**

04. 모델 설계

PCA 차원 축소

PCA 차원 축소의 필요성

- KCBERT 임베딩 결과로 768차원의 고차원 벡터 생성
 - 메타데이터와 그대로 결합할 경우, **임베딩 차원이 상대적으로 큼**
 - 모델 학습 시 과적합 가능성 존재 및 계산 비용 증가
 - **검증 및 테스트 용 데이터**는 학습 데이터에서 추출한 고유 벡터값으로 **단순 적용**하여 데이터 누수 방지
 - **학습, 검증, 테스트 데이터 비율 70% : 15% : 15%**

전체 임베딩 형태: (8840, 768)

학습 임베딩 형태: (6188, 768)

검증 임베딩 형태: (1326, 768)

테스트 임베딩 형태: (1326, 768)

- 위 문제를 방지하기 위해 학습용 데이터에 **PCA 기반 차원 축소 수행**
 - 텍스트 의미 정보를 최대한 유지하면서 차원 축소
 - KCBERT 임베딩의 누적 설명 분산 90%를 보존 수준 채택
 - **과적합 가능성 완화 및 계산 비용 감소**

차원 축소 전 학습 데이터 형태: (6188, 768)

차원 축소 후 학습 데이터 형태: (6188, 143)

차원 축소 후 검증 데이터 형태: (1326, 143)

차원 축소 후 테스트 데이터 형태: (1326, 143)

04. 모델 설계

메타데이터 정규화 및 융합

메타데이터 정규화

- 메타데이터를 PCA 임베딩에 결합하기 위한 **정규화** 진행
- 별점, 텍스트 길이, 이모지 수, 사진 수의 값의 범위를 맞추기 위한 정규화

스케일링 전 학습 메타데이터 예시:

[5. 40. 0. 3.]

스케일링 후 학습 메타데이터 예시:

[0.22184341 -0.28172543 -0.16495297 2.77035697]

학습 메타데이터 형태: (6188, 4)

검증 메타데이터 형태: (1326, 4)

테스트 메타데이터 형태: (1326, 4)

메타데이터와 PCA 임베딩 결과 융합

- 차원 축소된 임베딩 벡터와 정규화된 메타데이터를 결합한 하이브리드 특징 벡터 생성
 - 최종 이진 분류용 모델의 입력으로 사용 가능
 - **PCA 임베딩 143개 + 메타데이터 4개 + 정답 label 1개**
 - 실제 모델에 입력되는 특성 수는 정답을 제외한 147개

PCA 차원 수: 143

최종 학습 데이터프레임 형태: (6188, 148)

최종 검증 데이터프레임 형태: (1326, 148)

최종 테스트 데이터프레임 형태: (1326, 148)

04. 모델 설계

최종 분류 모델: Scikit-learn MLP Classifier

모델 선정 이유

- 최종 입력 데이터는 이미지 형태가 아닌 **숫자형 특징 벡터**
- 프로젝트 목표는 '**리뷰 이벤트성 리뷰인가 아닌가**' 분류 문제
 - 숫자 형태의 특징 벡터를 입력받아 분류하는 구조
 - **따라서 MLP 기반 이진 분류 모델 적용**
 - 또한, MLP는 KCBERT 임베딩과 메타데이터 사이의 **비선형 관계를 학습** 가능
- 이벤트성 리뷰일 확률값 출력 가능
 - 이후 확률을 별점 정제 시 가중치 형태로 활용 가능

04. 모델 설계

클래스 불균형 문제 해소: SMOTE 적용

SMOTE 기법의 필요성

- 탐색적 데이터 분석 결과, 이벤트 리뷰 데이터가 일반 리뷰 데이터에 비해 적어 **모델이 일반 리뷰로 중심으로 편향될 위험이 존재함**
 - 데이터를 추가 수집하여 비율을 맞춰도 여전히 격차는 존재
 - 단순 텍스트 증강은 이벤트 여부를 판단하는 핵심 단어 삭제 가능성 존재 / 단순 복제는 과적합을 유발
- 따라서 소수 클래스의 합성 샘플을 생성하는 SMOTE 기법을 채택

05. 실험 및 평가 방법

실험 설계

데이터 분할

- Train 학습 / Validation 검증 / Test 테스트 데이터를 **70% / 15% / 15%**로 분할
- 이후 학습 데이터에만 SMOTE를 적용하여 검증과 테스트 데이터 보존
- PCA 차원 축소 적용 전에 분할

데이터 교차 검증

- 학습 과정 중 학습 데이터에 대한 과적합을 방지하고 최적의 하이퍼파라미터를 찾기 위해 **5-Fold 교차 검증(Cross-Validation)** 적용

05. 실험 및 평가 방법

베이스라인 모델 설정

베이스라인 1 (전통적 기법)

- 텍스트 TF-IDF 임베딩 + Random Forest Classifier

베이스라인 2 (핵심)

- 행동 메타데이터만 입력한 MLP Classifier

베이스라인 3 (핵심)

- KcBERT 임베딩만 입력한 MLP Classifier

절제 연구(Ablation Study) 설계

- 제안하는 하이브리드 구조에서 각 요소가 얼마나 중요한 역할을 하는지 확인하기 위해 모델의 구성을 하나씩 제거하여 실험해보는 방법
- 메타데이터만 사용했을 때, 텍스트 임베딩만 사용했을 때, 그리고 두 가지를 모두 결합했을 때의 성능을 각각 측정하여 두 데이터를 융합하는 방식이 실제로 모델 성능 향상에 기여하는지 검증할 계획

05. 실험 및 평가 방법

모델 성능 평가 지표

단순 정확도(Accuracy) 배제

- 일반 리뷰가 압도적으로 많은 배달 앱에서는 모델이 데이터를 아예 안 보고 찍어도 정확도가 높게 치솟는 착시가 발생

핵심 평가 지표

- F1-Score: 가짜 리뷰를 하나도 놓치지 않는 **재현율(Recall)**과, 지목한 리뷰가 진짜 가짜일 **정밀도(Precision)**를 보여주기 때문에 가장 중요한 평가 기준으로 채택
- PR-AUC: 모델의 **전반적인 예측 성능**을 확인하기 위해 함께 측정할 계획
 - 곡선 면적을 측정하여 모델의 본질적 분류 성능 평가
 - 클래스 불균형 데이터에 ROC-AUC보다 적합

06. 실험 결과 및 해석

베이스라인 vs 제안 모델 성능 비교 계획

- 제안한 하이브리드 모델과 베이스라인 모델들의 성능을 동일 조건에 비교하여, **KcBERT 임베딩 결과에 메타데이터를 결합한 전략이 탐지율을 얼마나 향상시켰는지 수치로 검증**할 계획
- 모델 예측에 **가장 큰 영향을 미친 메타데이터의 영향도를 분석**할 계획
→ 이를 통해 이벤트 참여자는 어떤 행동 패턴을 보이는지에 대한 인사이트 도출 예정

오답 데이터 해석 계획

- 모델이 분류에 실패한 **오답 리뷰 데이터들을 별도로 추출하여 그 원인을 분석**
- KcBERT 모델이 은어나 신조어 같은 우회된 텍스트를 예측할 때 어떤 한계가 있는지 파악
- 추출한 메타데이터가 이러한 언어적 모호성의 오답을 줄이는 데 어떻게 기여했는지 점검하여 향후 모델을 개선할 방향을 도출할 계획

06. 실험 결과 및 해석

분류 모델 실제 적용

별점 정제 계획 후보1: 이벤트 리뷰 제외

- 정제된 별점 = 일반 리뷰 별점 합 / 일반 리뷰 개수
- 리뷰 이벤트성 리뷰라고 판단되면 아예 제외

예시

- A: 5점 (이벤트), B: 5점(이벤트), C: 5점(일반), D: 4점(일반)
- 기존 별점 평균: $(5+5+5+4)/4 = 4.75$
- 정제 별점 평균: $(5+4)/2 = 4.5 \rightarrow$ 이벤트성 리뷰 제외

장점: 구현 용이, 계산 과정 명확, 비교 쉬움

단점: 모델 분류 오류 시, 일반 리뷰 제외됨, 이벤트 리뷰의 **실제 객관적 정보 손실 발생**

06. 실험 결과 및 해석

별점 정제 계획 후보2: 확률 기반 가중 평균

- 모델이 예측한 확률 기준 리뷰별 반영 비율 조정
- 리뷰 이벤트 확률이 높으면 해당 별점의 반영 비율을 낮춤
- $\text{가중치} = (1 - \text{리뷰 이벤트 확률}) / \text{정제 별점} = \Sigma(\text{별점} \times \text{가중치}) / \Sigma(\text{가중치})$

예시

- A: 5점 (0.75), B: 5점(0.8), C: 5점(0.1), D: 4점(0.0)
- 가중치: 0.25, 0.2, 0.9, 1.0
- 별점 x 가중치: 1.25, 1.00, 4.50, 4.00
- $\Sigma(\text{별점} \times \text{가중치}): 1.25 + 1.00 + 4.50 + 4.00 = 10.75$
- $\Sigma(\text{가중치}): 0.25 + 0.20 + 0.90 + 1.00 = 2.35$
- 정제 별점 = $10.75 / 2.35 = \text{약 } 4.57$

06. 실험 결과 및 해석

별점 정제 계획 후보2: 확률 기반 가중 평균

장점

- 리뷰 이벤트를 제거하지 않아서 정보 손실 최소화
- 단순 제외 방식보다 유연함
- 기존 평균 별점과 정제 별점의 차이로 이벤트의 영향 분석 가능

한계점

- 모델의 예측이 부정확 시, 정제 별점에 영향
- 가중치 방식에 대한 검증 필요
- 리뷰 수가 적은 가게는 가중치 변화에 정제 별점 변동이 크게 변동될 수 있음
- 모든 리뷰가 이벤트성으로 판별되어 가중치 합이 특정 임계치 이하로 떨어질 경우, 신뢰도가 낮아질 수 있음

최종 판단: 후보2 (확률 기반 가중 평균)를 채택

- 후보 1과 2의 장점과 한계점을 비교했을 때, 프로젝트 목표에 적합하다고 판단

07. 프로젝트 일정 및 역할 분배

프로젝트 진행 현황 (수행 완료)

3~5주차: 데이터 수집 및 라벨링

- 해시스크래퍼를 활용하여 배민 리뷰 데이터 크롤링
- 주문 메뉴명 기반 리뷰 이벤트 라벨링

6~9주차: 전처리 작업

- KcBERT 임베딩 벡터 추출
- 임베딩 벡터값과 행동 메타데이터 결합하여 최종 CSV 산출
- 데이터 7:1.5:1.5 분할
- 학습 데이터에 PCA 적용
- 학습 데이터 한정 SMOTE 기법 적용

07. 프로젝트 일정 및 역할 분배

향후 남은 일정 계획

업무	10주차	11주차	12주차	13주차	14주차	15주차
제안 모델 및 베이스라인 구축						
5-Fold 교차 검증 및 하이퍼파라미터 튜닝						
모델 비교 실험 및 성능 평가						
절제 연구 및 오류 분석 수행						
별점 평균 정제 로직 구현						
프로젝트 최종 분석 및 보고서 작성						

07. 프로젝트 일정 및 역할 분배

팀원별 수행 역할

팀원	담당 역할	주요 업무
원재연	프로젝트 총괄 및 성능 평가	- 프로젝트 전체 마일스톤 관리 및 결과 취합 - F1/PR-AUC 지표 기반 성능 분석
김준영	특성 추출 및 융합, 모델 훈련, 문서 작성	- 사전학습 모델(KcBERT) 환경 구축 및 임베딩 벡터 추출 - 데이터 결합을 위한 PCA 차원 축소 파이프라인 및 하이브리드 특성 융합 - 제안 분류 모델 훈련
김현섭	데이터 전처리 및 별점 정제 로직 설계, 문서 작성	- 텍스트/메타데이터 정제 및 파생 변수 생성 - 모델 예측 확률 기반 별점 정제 알고리즘 수식 설계
이연준	베이스라인 구축 및 비교 분석 설계	- 베이스라인 모델(TF-IDF+RF 등) 파이프라인 구축 - 하이브리드 모델의 객관적 검증을 위한 절제 연구(Ablation Study) 설계
최건희	제안 분류 모델 구축 및 최적화	- 제안 MLP 분류기 구조 구현 및 학습 - 과적합 방지를 위한 5-fold 교차 검증 수행 - 은닉층 및 L2 정규화 등 하이퍼파라미터 탐색 및 튜닝

08. 중간 결론 및 향후 계획

중간 결론 요약

- 리뷰 이벤트 전용 주문 메뉴를 포함한 데이터 수집 및 라벨링 완료
- 고차원의 텍스트 임베딩과 저차원의 사용자 행동 메타데이터를 결합하기 위한 데이터 전처리
- 분할 및 클래스 불균형(SMOTE) 해결 파이프라인 세팅 완료

발생한 문제점

- 배달 리뷰 생태계 특성상 **일반 리뷰와 이벤트 리뷰 간의 구분이 어려운 것**을 확인
- 사전 학습된 KcBERT 모델을 단순 특징 추출기로만 사용할 경우 **탐지율(Recall) 향상에 한계가 존재할 것**으로 판단됨

향후 연구 계획

- KcBERT를 배민 데이터에 맞게 **가중치를 다시 학습시키는 fine-tuning**을 고려
- 제안 모델이 베이스라인 대비 실제로 얼마나 성능을 향상시키는지 **F1-Score 및 PR-AUC 지표로 객관적으로 검증**할 계획

THANK YOU

Q&A